

$$3) \quad \underline{x} \in \mathbb{R}^N \text{ og } \underline{a} \in \mathbb{R}^N$$

①

$$\underline{x} = [x_1, x_2, \dots, x_N]$$

$$\underline{a} = [a_1, a_2, \dots, a_N]$$

$$\underline{x}^T \cdot \underline{a} = x_1 a_1 + x_2 a_2 + \dots + x_N a_N$$

$$\frac{\partial}{\partial \underline{a}} = \left[\frac{\partial}{\partial a_1}, \frac{\partial}{\partial a_2}, \frac{\partial}{\partial a_3}, \dots, \frac{\partial}{\partial a_N} \right]$$

$$\begin{aligned} \frac{\partial}{\partial \underline{a}} (\underline{x}^T \underline{a}) &= \left[\frac{\partial}{\partial a_1} (x_1 a_1 + \cancel{x_2 a_2 + \dots}), \right. \\ &\quad \frac{\partial}{\partial a_2} (\cancel{x_1 a_1} + x_2 a_2 + \cancel{\dots}), \\ &\quad \vdots \\ &\quad \left. \frac{\partial}{\partial a_N} (\cancel{x_1 a_1 + x_2 a_2 + \dots} + x_N a_N) \right] \end{aligned}$$

$$= [x_1, x_2, \dots, x_N] = \underline{x}$$

$$4) \hat{P}(c_1 | x) > \theta, \quad 0 < \theta < 1$$

(2)

$$FP = N \cos\left(\frac{\pi\theta}{2}\right), \quad N: \# \text{ Negative samples}$$

$$TP = T \cos\left(\frac{\pi\theta}{2}\right) \left(2 - \cos\left(\frac{\pi\theta}{2}\right)\right), \quad T: \# \text{ Pos. sample}$$

a) Def: $f_p = \frac{FP}{FP + TN}$ or $t_p = \frac{TP}{TP + FN}$

Konfusion matrix:

	Actual Pos	Actual Neg
Predicted Pos	TP	FP
Predicted Neg	FN	TN

$$N = TN + FP$$

$$T = TP + FN$$

$$\hookrightarrow f_p = \frac{N \cos\left(\frac{\pi\theta}{2}\right)}{N} = \cos\left(\frac{\pi\theta}{2}\right) \quad \swarrow x$$

$$t_p = \frac{T \cos\left(\frac{\pi\theta}{2}\right) \left(2 - \cos\left(\frac{\pi\theta}{2}\right)\right)}{T}$$

$$= \underbrace{\cos\left(\frac{\pi\theta}{2}\right)}_{f_p} \left(2 - \underbrace{\cos\left(\frac{\pi\theta}{2}\right)}_{f_p}\right) \quad \swarrow y$$

b) ROC - curve : La θ variere mellem $[0, 1]$

Plot t_p mot f_p .

c) AUC - score : $\int_0^1 y(x) dx$ (areal under "kurven")

3

$$y = t_p = f_p(2 - f_p) = x(2 - x) = -x^2 + 2x$$

$$A = \int_0^1 (-x^2 + 2x) dx = \left[-\frac{1}{3}x^3 + \frac{1}{2} \cdot 2x \right]_0^1 = 1 - \frac{1}{3} = \underline{\underline{\frac{2}{3}}}$$

Soft - classifications - X. csv

(4)

	<u>Ground truth</u>		<u>Probability</u>	
$x^{(1)}$	1	$\hat{p}^{(1)}$	0,9928	Hvis terskel
$x^{(2)}$	1	$\hat{p}^{(2)}$	0,99540	$\theta = 0,5$ så vil
$x^{(3)}$	1	$\hat{p}^{(3)}$	0,97839	denne være
$x^{(4)}$	0	$\hat{p}^{(4)}$	0,53893	feil -
\vdots		\hat{p}		klassifisert

True positives

False positives

Rett klassifisert om $\theta = 0,6$ skrinot

Betyr at TP-rate og FP-rate avhenger av terskelverdi θ for klassifisering som True/False!

$$t_p = \frac{TP}{TP + FN} \quad \leftarrow \begin{array}{l} \text{Totalt \#} \\ \text{egentlige} \\ \text{positive} \end{array}$$

Skulle egentlig vært positive!

$$f_p = \frac{FP}{FP + TN} \quad \leftarrow \begin{array}{l} \text{Tot \#} \\ \text{eg.} \\ \text{negative} \end{array}$$

Skulle eg. vært negativ

t_p kalles også "Recall" i litteraturen, eller også sensitivitet. Innen medisin er dette en faktor som man ønsker høyst mulig! (kan også stå på begrepet "precision" = $\frac{TP}{TP + FP}$)

Ofte fører økt recall til lavere presisjon og motsatt...

ROC står for Receiver Operating Characteristic (5)

og plottes t_p mot f_p , altså t_p på y-akse og f_p på x-akse.

5a) Forslag algoritme:

1) Bræk første kolonne til 2 dele ssh. kolonne
i samples $\underline{\mu_+}$ og $\underline{\mu_-}$

2) True positives finder vi i subsettet
 $\underline{\mu_+} > \theta$ og true negatives i $\underline{\mu_-} \leq \theta$

Længden af disse blir da TP og TN.

3) FP finder vi da for $\underline{\mu_-} > \theta$ og
FN for $\underline{\mu_+} \leq \theta$