

Linja kan også skrives som $\underline{x} \cdot \underline{w}^T = 0$, der vektene $\underline{w} = [w_2, w_1, w_0]$ og $\underline{x} = [x_2, x_1, 1]$

↳ Ønsker å finne alg. for å ^{best mulig}bestemme \underline{w} gitt et trenings-sett $\underline{X} = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_m^{(1)} \\ \vdots & \vdots & & \vdots \\ x_1^{(n)} & x_2^{(n)} & \dots & x_m^{(n)} \end{bmatrix}$ ← Samples

↓
Features

Binær klassifisering : Lære opp en hypotese-funksjon

$h_{\underline{w}}(\underline{x})$ som angir en sannsynlighet.

$\hat{p} \in [0, 1]$ for $x (=1)$ eller $0 (=0)$

(2)


Modell : $h_w(\underline{x}) = \sigma(\underline{w}^T \underline{x})$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Et tall etter
prikk-produkt.

↳ Sigmoid / logistiske funksjon

↳ Separerer samplene et sted mellom 0 og 1.



Kostfunksjonen : Et tall som angir "feilen" mellom
modell og virkelighet

Lineær regresjon : $J(\beta_0, \beta_1) = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$

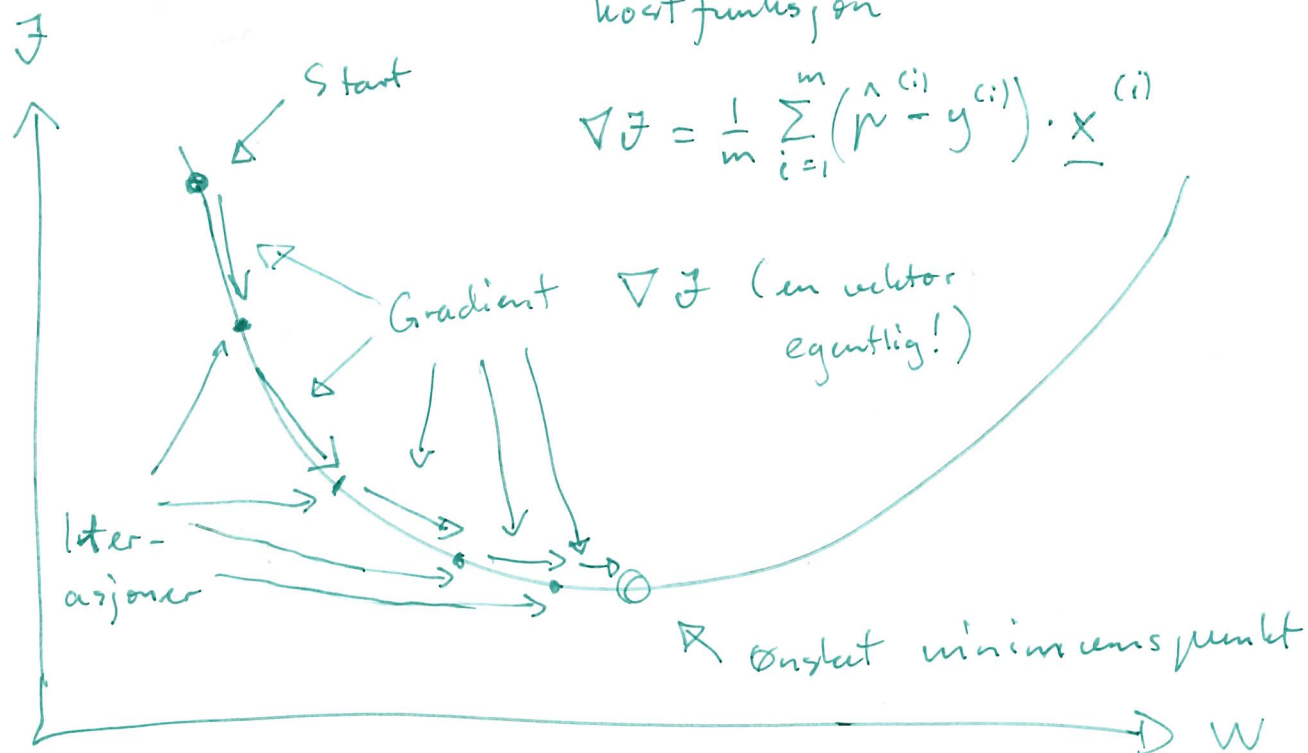
der $\hat{y}^{(i)} = \beta_0 + \underline{x}^{(i)} \beta_1$

Logistisk regresjon : Bruker $\hat{p}^{(i)} = \sigma(\underline{w}^T \underline{x}^{(i)})$

Kostfunksjon : $J(\underline{w}) = -\frac{1}{m} \sum y^{(i)} \log(\hat{p}^{(i)})$
 $+ (1 - y^{(i)}) \log(1 - \hat{p}^{(i)})$

Gradient descent : Bevegeelse mot min. av kostfunksjon

(3)



epochs = 100 (or so) ; learn-rate = 0.01

for epoch in range(epochs):

tot-error = 0

for i in range(m):

pick random index r

$\underline{x} = X[r, :]$

$y = y[r]$

$\hat{y} = \text{sigmoid}(\underline{x} \cdot \underline{w})$

gradient = $(\hat{y} - y) \cdot \underline{x}$

$\underline{w} = \underline{w} - \text{learn-rate} \cdot \text{gradient}$

tot-error += $(\hat{y} - y)^2$

tot-error = tot-error / m

Sample i array og plot etterpå

Enten
0 eller
1

Stochastic
grad. descent.